

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет о программном проекте на тему:

**Прогнозирование волатильности рынка драгоценных металлов с учётом
настроений инвесторов**

Выполнил:

студент группы БПМИ249

Лапшин Владислав Анатольевич

подпись

дата

Принял руководитель проекта:

Куренков Владимир Вячеславович

Старший преподаватель

Факультет компьютерных наук / Департамент больших данных и информационного поиска

подпись

дата

Москва 2026

Содержание

Введение	5
Актуальность темы исследования	5
Постановка проблемы	5
Цель и задачи проекта	5
Обоснование выбора инструментов и технологий	6
1 Обзор литературы	7
1.1 Модели волатильности	7
1.2 Attention и sentiment в прогнозировании	7
1.3 Машинное обучение для прогнозирования волатильности	8
1.4 Волатильность рынка драгоценных металлов	8
2 Описание функциональных и нефункциональных требований	8
2.1 Общее описание системы	8
2.2 Функциональные требования	8
2.3 Нефункциональные требования	10
3 Сравнение с существующими аналогами	10
3.1 Коммерческие платформы	10
3.2 Открытые библиотеки	10
3.3 Академические системы	11
3.4 Сводная таблица сравнения	11
4 Архитектура программного комплекса	12
4.1 Общая структура	12
4.2 Подсистема сбора данных	12
4.3 Подсистема обработки признаков	13
4.4 Модельный модуль	13
4.5 Веб-интерфейс	14
4.6 Демонстрация системы с точки зрения пользователя	15
5 Данные	15
5.1 Котировки драгоценных металлов	15
5.2 Реализованная волатильность	16
5.3 Sentiment и attention признаки	17
5.3.1 Новостной поток (RSS)	17
5.3.2 Telegram-каналы	17
5.3.3 GDELT	18
5.3.4 Google Trends	18
5.3.5 Макроэкономические индикаторы	18

5.3.6	Объёмы торгов MOEX	18
5.4	Итоговый датасет	18
6	Методология	19
6.1	HAR-RV модель	19
6.2	Схема оценки out-of-sample	20
6.3	Метрики качества	20
6.4	XGBoost	21
6.5	kNN на пространстве информационных состояний	21
6.6	Вычислительная сложность и обоснование оптимальности	22
7	Результаты	22
7.1	HAR-RV бенчмарк	22
7.2	HAR-log-S с многоисточниковым sentiment-вектором	23
7.3	Ablation: вклад отдельных sentiment-источников	23
7.4	kNN на пространстве информационных состояний	24
7.5	XGBoost	24
7.6	Сравнительный анализ и тест Диболда–Мариано	26
7.7	Главные выводы	27
7.8	Ограничения и направления развития	28
8	Тестирование программного комплекса	28
8.1	Стратегия тестирования	28
8.2	Модульные тесты	28
8.2.1	Тестирование вычисления реализованной волатильности	28
8.2.2	Тестирование парсеров	28
8.2.3	Тестирование HAR-модели	29
8.2.4	Тестирование XGBoost	29
8.3	Интеграционное тестирование	29
8.4	Системное тестирование	30
8.5	Объёмные характеристики кода и данных	30
8.6	Валидация данных	31
9	Заключение	31
10	Описание применения генеративной модели	33

Аннотация

Работа посвящена разработке программного комплекса для прогнозирования реализованной волатильности рынка драгоценных металлов Московской биржи (золото GLDRUB_TOM, серебро SLVRUB_TOM) с учётом настроений и внимания инвесторов. В качестве бенчмарка используется модель HAR-RV и её расширение HAR-log-S, в которое включён лагированный многоисточниковый sentiment-индекс (RSS, GDELT, Telegram, Google Trends). В сравнительный анализ дополнительно включены XGBoost и kNN-поиск исторически похожих информационных состояний на пространстве HAR-лагов и sentiment-вектора. Лучший результат для золота показывает HAR-log-S ($R^2_{OOS} = 0,180$ против 0,177 у бенчмарка), для серебра — классическая HAR-log ($R^2_{OOS} = 0,377$). По тесту Диболда–Мариано улучшение от sentiment значимо лишь на уровне 10%; XGBoost и kNN уступают HAR-моделям на обоих инструментах. Ablation-анализ выявил различие сильнейшего источника между активами: для золота это взвешенный sentiment_combined, для серебра — индекс внимания Google Trends. Дополнительный методологический вклад — единый модуль метрик с канонической Patton QLIKE и тестом Диболда–Мариано, обеспечивающий корректное попарное сравнение моделей.

Ключевые слова: реализованная волатильность, HAR-RV, XGBoost, kNN, sentiment-анализ, внимание инвесторов, Google Trends, GDELT, MOEX, драгоценные металлы.

Введение

Актуальность темы исследования

Волатильность финансовых активов является одним из ключевых понятий в современных финансах: она определяет стоимость опционов, влияет на управление рисками портфелей и служит индикатором неопределённости на рынке. Особый интерес представляет волатильность рынка драгоценных металлов — золота, серебра, платины и палладия, — которые традиционно выступают защитными активами в периоды геополитической нестабильности и инфляционного давления.

Начиная с 2022 года российский рынок драгоценных металлов претерпел значительные структурные изменения: введение западных санкций, ограничение доступа к международным площадкам и существенное изменение режима волатильности делают прогнозирование на основе исторических закономерностей недостаточным. В этих условиях особую ценность приобретают методы, способные учитывать *настроения инвесторов* и *информационные шоки* — реакцию рынка на новостной поток, изменения ключевой ставки, геополитические события.

Постановка проблемы

Традиционные модели прогнозирования волатильности опираются в основном на прошлые ценовые данные и плохо учитывают информационный фон рынка. При этом неочевидно, помогает ли добавление настроений и внимания инвесторов прогнозировать волатильность российских драгоценных металлов и какие именно источники полезны. Эту задачу и решает настоящая работа.

Настоящая работа посвящена разработке системы прогнозирования реализованной волатильности (Realized Volatility, RV) инструментов Московской биржи. Программный комплекс собирает данные по всем четырём металлам — GLDRUB_TOM (золото), SLVRUB_TOM (серебро), PLTRUB_TOM (платина) и PLDRUB_TOM (палладий), — однако содержательный эконометрический анализ сосредоточен на золоте и серебре: для платины и палладия длина доступного ряда на MOEX недостаточна для надёжной оценки в режиме расширяющегося окна (см. раздел 7). В качестве бенчмарка используется классическая HAR-RV модель [4], которая расширяется за счёт sentiment- и attention-признаков, извлекаемых из разнородных источников данных.

Цель и задачи проекта

Цель работы — разработать программный комплекс для прогнозирования реализованной волатильности российских драгоценных металлов, который объединяет эконометрические и ML-модели с многоисточниковым вектором настроений и внимания инвесторов и предоставляет веб-интерфейс для интерактивной визуализации прогнозов и sentiment-индексов.

Задачи:

1. Сформировать панельный датасет дневных OHLCV-котировок драгоценных металлов на MOEX за период 2018–2026 гг. и вычислить реализованную волатильность оценщиком Garman–Klass (в коде также реализованы альтернативные оценщики Parkinson и Rogers–Satchell).

2. Собрать многоисточниковый sentiment/attention вектор: новостной поток (RSS, GDELT), поисковые запросы (Google Trends), объёмы торгов MOEX, макроэкономические индикаторы (ЦБ РФ, FRED).
3. Оценить HAR-RV бенчмарк и его расширения с sentiment-признаками методом расширяющегося окна (expanding window OOS).
4. Реализовать и обучить модели машинного обучения на том же наборе признаков — градиентный бустинг XGBoost и kNN-прогнозировщик на пространстве информационных состояний (по методологии Halousková и Lyócsa) — и сравнить их с эконометрическим бенчмарком, в том числе по тесту Диболда–Мариано.
5. Разработать веб-приложение для визуализации прогнозов волатильности и sentiment-индексов в режиме реального времени.

Научная новизна работы заключается в адаптации подхода Halousková и Lyócsa [10] — прогнозирования волатильности через макроэкономический attention — к условиям российского рынка драгоценных металлов с учётом специфики доступных источников данных (русскоязычный новостной поток, GDELT, данные MOEX).

Практическая значимость. Главная ценность работы — это законченный программный комплекс: от сбора семи источников данных и расчёта волатильности до сравнения четырёх моделей и веб-визуализации (более 5000 строк кода, см. раздел 8.5). Кроме того, в работе сделан единый модуль метрик с QLIKE [14] и тестом Диболда–Мариано [6]. Видно, что добавление sentiment даёт лишь небольшой и слабо значимый выигрыш для золота, а классическая HAR-log остаётся сильным бенчмарком. Этот результат сам по себе полезен для риск-менеджмента.

Обоснование выбора инструментов и технологий

Выбор инструментов определялся задачей и доступными данными. Весь комплекс написан на Python из-за богатой экосистемы для анализа данных и машинного обучения (pandas, numpy, scikit-learn, xgboost). В качестве бенчмарка взята модель HAR-RV, а не GARCH: она проста, интерпретируема и хорошо работает на дневных данных. Для нелинейного сравнения добавлены XGBoost (стандарт для табличных данных) и kNN на пространстве информационных состояний (по методологии Halousková и Lyócsa). Веб-интерфейс сделан на лёгком фреймворке Flask с интерактивными графиками Plotly. Все источники данных — бесплатные и общедоступные (MOEX ISS, GDELT, Google Trends, ЦБ РФ, FRED, RSS, Telegram), что обеспечивает воспроизводимость результатов.

1 Обзор литературы

1.1 Модели волатильности

Исследование волатильности финансовых активов берёт начало с работ Энгла [7] (модель ARCH) и Боллерслева [2] (GARCH), которые моделируют условную дисперсию доходностей как функцию прошлых наблюдений. Однако GARCH-модели плохо работают на высокочастотных данных и требуют сильных предположений о распределении остатков.

Ключевым вкладом в область прогнозирования волатильности стала модель HAR-RV (Heterogeneous Autoregressive model of Realized Volatility), предложенная Корси [4]. Модель основана на гипотезе рыночной гетерогенности: разные участники рынка (краткосрочные трейдеры, институциональные инвесторы, пенсионные фонды) действуют на различных временных горизонтах — дневном, недельном и месячном. Спецификация HAR-RV:

$$RV_{t+1} = \beta_0 + \beta_d RV_t^{(d)} + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+1}, \quad (1)$$

где $RV_t^{(d)}$, $RV_t^{(w)}$, $RV_t^{(m)}$ — среднеарифметические реализованные волатильности за последние 1, 5 и 22 торговых дня соответственно; β_0 — свободный член, а β_d , β_w , β_m — коэффициенты при дневной, недельной и месячной компонентах, оцениваемые методом наименьших квадратов; ε_{t+1} — случайная ошибка (остаток модели). Несмотря на линейность, модель (1) показывает хорошие результаты на многих рынках [4].

Для оценки качества прогнозов в работе используется QLIKE-функция потерь [14]. Её удобство в том, что она остаётся корректной, даже когда вместо ненаблюдаемой «истинной» волатильности подставляется её оценка (прокси):

$$QLIKE = \mathbb{E} \left[\frac{RV_t}{\hat{\sigma}_t^2} - \ln \frac{RV_t}{\hat{\sigma}_t^2} - 1 \right]. \quad (2)$$

1.2 Attention и sentiment в прогнозировании

Тетлок [16] одним из первых продемонстрировал, что тональность публикаций в Wall Street Journal предсказывает доходности и объёмы торгов на фондовом рынке. Да, Энгельберг и Гао [5] предложили использовать индекс поисковой активности Google как прямую меру внимания розничных инвесторов и показали его связь с будущими доходностями.

Работа Halousková и Lyócsa [10] лежит в основе настоящей работы. Авторы строят вектор «макроэкономического внимания» — набор признаков, отражающих интерес инвесторов к макроэкономическим анонсам (инфляция, ставка ФРС, ВВП и др.) — и показывают, что его добавление в HAR-модель заметно улучшает прогноз волатильности акций США. Настоящая работа адаптирует этот подход к российскому рынку драгоценных металлов, заменяя американские анонсы на решения ЦБ РФ, геополитические события и данные русскоязычного новостного потока.

Для извлечения sentiment из финансовых текстов широко применяются модели на основе BERT [1]. FinBERT, обученный на финансовых новостях и аналитике, работает заметно лучше словарных методов при классификации тональности финансовых текстов. В настоящей работе

используется русскоязычная модель ruBERT для обработки новостей российских СМИ.

1.3 Машинное обучение для прогнозирования волатильности

Ченом и Гестрином [3] была предложена библиотека XGBoost — реализация градиентного бустинга с регуляризацией, — ставшая стандартом в задачах прогнозирования на табличных данных. Применительно к финансовым временным рядам XGBoost позволяет нелинейно комбинировать NAR-признаки с sentiment-вектором без явного задания функциональной формы.

Рекуррентные нейронные сети, в частности LSTM [11], способны улавливать долгосрочные зависимости в последовательностях, что делает их естественным выбором для моделирования волатильности с явной последовательной структурой.

1.4 Волатильность рынка драгоценных металлов

Рынок драгоценных металлов характеризуется рядом особенностей, отличающих его от рынков акций: высокой чувствительностью к геополитическим событиям и инфляционным ожиданиям, ролью золота как «safe haven» актива и значительным влиянием курса доллара США на рублёвые цены инструментов МОЕХ. Российский рынок металлов после 2022 года приобрёл дополнительную специфику в связи с ограничениями на экспорт и реструктуризацией торговых потоков, что создаёт нетривиальные задачи для прогнозирования.

2 Описание функциональных и нефункциональных требований

2.1 Общее описание системы

Разрабатываемый программный комплекс представляет собой модульную систему для сбора данных, обучения моделей прогнозирования волатильности и визуализации результатов. Система реализована на языке Python 3.11+ и состоит из четырёх подсистем: сбора данных, обработки и агрегации признаков, модельного модуля и веб-интерфейса.

2.2 Функциональные требования

Подсистема сбора данных обязана:

1. Загружать дневные OHLCV-котировки инструментов GLDRUB_TOM, SLVRUB_TOM, PLTRUB_TOM, PLDRUB_TOM с MOEX ISS API за произвольный исторический период.
2. Парсить новостные RSS-ленты российских финансовых СМИ (Коммерсантъ, Ведомости, Интерфакс, ТАСС, РБК, Investing.com) с фильтрацией по ключевым словам, связанным с металлами и макроэкономикой.

3. Загружать данные GDELT Global Knowledge Graph за заданный период и извлекать дневные агрегаты тональности (Tone) и количества статей.
4. Получать индексы поисковой активности Google Trends по релевантным запросам через библиотеку pytrends.
5. Загружать официальные курсы валют (USD/RUB, EUR/RUB, CNY/RUB) и историю ключевой ставки с XML API Банка России.
6. Загружать макроэкономические ряды (нефть Brent, VIX, DXY, CPI США) через FRED API.
7. Все источники данных должны поддерживать инкрементальное обновление: повторный запуск не перезаписывает существующие данные.

Подсистема обработки признаков обязана:

1. Вычислять дневную реализованную волатильность из OHLCV-данных методами Garman–Klass, Parkinson, Rogers–Satchell и Close-to-Close.
2. Формировать HAR-лаги ($RV^{(d)}$, $RV^{(w)}$, $RV^{(m)}$) для каждого инструмента.
3. Агрегировать все источники sentiment и attention в единый дневной CSV-файл с полным временным покрытием.

Модельный модуль обязан:

1. Реализовывать HAR-RV модель в трёх спецификациях: уровни (HAR-level), логарифмы (HAR-log) и логарифмы с sentiment (HAR-log-S).
2. Проводить оценку методом расширяющегося окна (expanding window) с метриками MAE, RMSE, QLIKE и R^2_{OOS} .
3. Реализовывать модели машинного обучения на тех же наборах признаков: градиентный бустинг XGBoost и kNN-прогнозировщик на пространстве информационных состояний.
4. Сохранять результаты прогнозов и метрики в CSV для последующего анализа.

Веб-интерфейс обязан:

1. Отображать исторический график реализованной волатильности с наложением прогнозов модели.
2. Отображать дашборд sentiment-индексов по источникам.
3. Обновляться при запуске скрипта обновления данных.

2.3 Нефункциональные требования

1. **Воспроизводимость.** Все случайные процессы фиксируются через `random_state=42`. Зависимости фиксируются в `requirements.txt`.
2. **Модульность.** Каждый источник данных реализован в отдельном модуле с единым интерфейсом командной строки.
3. **Расширяемость.** Добавление нового источника данных не требует изменения модельного модуля.
4. **Производительность.** Полный цикл обновления данных и переобучения моделей должен завершаться не более чем за 30 минут на стандартном ноутбуке.
5. **Открытость данных.** Все используемые источники данных должны быть бесплатно доступны без ограничений на некоммерческое использование.

3 Сравнение с существующими аналогами

Разработанная система прогнозирует волатильность с помощью альтернативных источников данных. Ниже рассмотрены наиболее близкие аналоги — коммерческие платформы, открытые библиотеки и академические системы.

3.1 Коммерческие платформы

Bloomberg Terminal / Refinitiv Eikon. Профессиональные терминалы предоставляют широкий набор инструментов для анализа волатильности: реализованную волатильность, подразумеваемую волатильность, исторические ряды VIX-подобных индексов. Тем не менее эти платформы ориентированы на западные рынки, не имеют готовых sentiment-моделей для русскоязычного контента, а доступ к данным по инструментам MOEX после 2022 г. существенно ограничен. Стоимость подписки (>\$20 000 в год) исключает использование в академических проектах.

MOEX Analytics. Официальный аналитический портал Московской биржи предоставляет исторические данные OHLCV и простые индикаторы волатильности (скользящее стандартное отклонение). Инструменты машинного обучения, альтернативные источники данных и функционал прогнозирования в платформе отсутствуют.

3.2 Открытые библиотеки

arch (Python). Библиотека `arch` [15] реализует широкий спектр GARCH-семейства моделей (GARCH, EGARCH, GJR-GARCH и др.) и является стандартом для параметрического моделирования волатильности. Однако библиотека не поддерживает HAR-RV модели, не имеет встроенного сбора данных и не работает с альтернативными источниками. Настоящая система использует HAR-RV как бенчмарк, а не GARCH, что обусловлено недоступностью высокочастотных данных.

FinRL (AI4Finance). Фреймворк для обучения с подкреплением в финансах [12] предоставляет среды для торговли акциями с базовыми техническими признаками. FinRL не ориентирован на задачу прогнозирования волатильности, не поддерживает sentiment-признаки из внешних API и не имеет модулей для работы с MOEX.

Qlib (Microsoft). Исследовательская платформа для количественных финансов [17] включает обширный набор ML-моделей для прогнозирования доходностей. Поддержка данных ограничена американскими и китайскими рынками; модуль прогнозирования волатильности отсутствует; русскоязычный sentiment не поддерживается.

3.3 Академические системы

В работе [10] предложена система прогнозирования волатильности акций США на основе вектора макроэкономического внимания. Настоящий проект является адаптацией этой методологии для российского рынка драгоценных металлов: заменены источники внимания (американские макро-анонсы → решения ЦБ РФ, русскоязычные Telegram-каналы, GDELT-тональность) и рыночные данные (S&P 500 → MOEX GLDRUB_TOM / SLVRUB_TOM).

3.4 Сводная таблица сравнения

Таблица 1: Сравнение разработанной системы с аналогами

Характеристика	<i>Bloomberg</i>	<i>arch</i>	<i>FinRL</i>	<i>Qlib</i>	<i>Наша система</i>
Данные MOEX	±	—	—	—	+
HAR-RV модель	—	—	—	—	+
XGBoost / kNN	—	—	+	+	+
Русскоязычный sentiment	—	—	—	—	+
Telegram-парсер	—	—	—	—	+
GDELT-тональность	±	—	—	—	+
Google Trends attention	—	—	—	—	+
Макро ЦБ РФ	—	—	—	—	+
Инкрементальное обновление	+	—	—	+	+
Веб-интерфейс	+	—	—	±	+
Открытый исходный код	—	+	+	+	+
Бесплатный доступ	—	+	+	+	+

Обозначения: «+» — поддерживается; «—» — отсутствует; «±» — частичная поддержка.

Видно, что среди рассмотренных решений нет ни одного, которое одновременно работает с данными MOEX, русскоязычным sentiment и моделями прогнозирования волатильности (HAR-RV, бустинг, kNN). Именно это сочетание и отличает разработанную систему от существующих аналогов для российского рынка драгоценных металлов.

4 Архитектура программного комплекса

4.1 Общая структура

Программный комплекс реализован на языке Python 3.11 и организован по принципу конвейера данных (data pipeline): независимые модули сбора данных формируют единый входной датасет, который передаётся в модельный модуль, а результаты прогноза отображаются через веб-интерфейс. Архитектура системы представлена на рисунке 1.




Рис. 1: Архитектура программного комплекса прогнозирования волатильности. Стрелки — направление потока данных.

4.2 Подсистема сбора данных

Каждый источник данных инкапсулирован в отдельном модуле в директории `src/data/`. Все парсеры поддерживают инкрементальное обновление: при повторном запуске новые данные дописываются к существующему файлу без перезаписи исторических наблюдений. Интерфейс командной строки унифицирован: параметры `--from` и `--to` задают временной диапазон выгрузки.

download_moex.py — загружает дневные OHLCV-котировки инструментов GLDRUB_TOM, SLVRUB_TOM, PLTRUB_TOM, PLDRUB_TOM через MOEX ISS REST API (формат JSON, пагинация по 100 записей). Выходной файл: `data/raw/<SECID>_1d.csv`.

parse_rss.py — парсит RSS-ленты шести финансовых изданий (Коммерсантъ, Ведомости, Интерфакс, ТАСС, РБК, Investing.com) с фильтрацией по 54 ключевым словам. Сентимент статей вычисляется моделью ruBERT (HuggingFace) для каждой статьи и агрегируется в дневной score.

parse_gdelt.py — загружает суточные CSV-архивы GDELT Global Knowledge Graph (GKG v2) за указанный период и извлекает усреднённый индекс тональности Tone по тематическим кластерам, связанным с золотом, серебром и российской экономикой.

parse_telegram.py — использует Telethon MTProto API для чтения 12 публичных русскоязычных каналов финансовой тематики (@russianmacro, @bcs_express, @cbrstocks, @markettwits и др.). Тексты фильтруются по 36 ключевым словам; лексический scorer взвешивает позитивные и негативные упоминания по числу просмотров сообщения.

parse_google_trends.py — загружает недельные индексы поисковой активности через pytrends по трём группам запросов (metals_ru, macro_ru, metals_en) и интерполирует до дневной частоты.

parse_cbr.py — обращается к XML API Банка России для получения официальных курсов валют (USD/RUB, EUR/RUB, CNY/RUB) и истории ключевой ставки.

parse_fred.py — загружает макроэкономические ряды через FRED API: нефть Brent (DCOILBRETEU), индекс доллара США (DTWEXBGS), волатильность VIX (VIXCLS), ставку ФРС (FEDFUNDS), CPI США (CPIAUCSL).

4.3 Подсистема обработки признаков

compute_rv.py принимает OHLCV-данные и вычисляет дневную реализованную волатильность четырьмя методами (Garman–Klass, Parkinson, Rogers–Satchell, Close-to-Close), формирует HAR-лаги $RV^{(d)}$, $RV^{(w)}$, $RV^{(m)}$ и сохраняет результат в data/processed/rv_features.csv.

aggregate_sentiment.py объединяет выходные файлы всех семи парсеров в единый датафрейм с дневной частотой. При слиянии применяется: *forward fill* для числовых рядов (курсы, макроэкономика), *заполнение нулями* для sentiment-переменных в дни без новостей, *z-score нормализация* с скользящим окном 30 дней для объёмов торгов и их sigmoid-преобразование. Итоговый файл daily_sentiment.csv содержит 25 признаков.

Комбинированный sentiment-индекс вычисляется как взвешенная сумма:

$$S_t^{\text{comb}} = 0,4 \cdot S_t^{\text{RSS}} + 0,4 \cdot S_t^{\text{GDELT}} + 0,2 \cdot S_t^{\text{Telegram}}, \quad (3)$$

где веса отражают качество покрытия: RSS и GDELT имеют более полное временное охватывание, чем Telegram-архив.

4.4 Модельный модуль

Модельный модуль разделён на два файла.

har_model.py реализует эконометрический пайплайн: формирование HAR-матрицы дизайна, оценку МНК с поправкой HAC (библиотека statsmodels), процедуру расширяющегося окна и расчёт метрик.

ml_models.py реализует основную модель XGBoost на расширенном наборе HAR-лагов и sentiment/attention-признаков с лагом 1 относительно целевой переменной. Используется библиотека xgboost; гиперпараметры приведены в разделе с описанием методологии. В модуле также реализован LSTM, но в итоговое сравнение он не вошёл: на дневной выборке такой длины его результаты оказались нестабильными. Все модельные классы (HARModel, XGBoostRV, LSTMRVModel) имеют единый интерфейс $\text{fit}(X, y), \text{predict}(X), \text{evaluate}(X, y) \rightarrow \text{dict}$, что позволяет легко добавлять

новые модели в общий пайплайн оценивания. Единая для всех моделей реализация метрик (MAE, RMSE, R^2_{OOS} , QLIKE) и тест Диболда–Мариано вынесены в модуль `src/models/metrics.py`.

Структура ключевых классов модельного модуля приведена в таблице 2.

Таблица 2: Ключевые классы и функции модельного модуля

Класс / функция	Модуль	Назначение и ключевые методы
HARModel	<code>models/har_model.py</code>	Эконометрическая HAR-RV модель. Атрибуты: <code>spec</code> (level/log/log_sentiment), <code>sentiment_col</code> , <code>train_frac</code> . Методы: <code>fit_rolling()</code> , <code>fit_full()</code> , <code>metrics()</code> , <code>save_results()</code> .
XGBoostRV	<code>models/ml_models.py</code>	Градиентный бустинг XGBoost на расширенном наборе признаков. Методы: <code>fit(X, y)</code> , <code>predict(X)</code> , <code>evaluate(X, y)</code> , <code>feature_importance()</code> .
LSTMRVModel	<code>models/ml_models.py</code>	Рекуррентная сеть (PyTorch) с early stopping; не используется в финальном сравнении из-за нестабильности на дневной выборке.
<code>run_knn(...)</code>	<code>models/knn_model.py</code>	Expanding-window kNN на пространстве HAR+sentiment с inverse-distance ядром и подобранными $k^* = 75/30$.
<code>compute_metrics(...)</code>	<code>models/metrics.py</code>	Единый расчёт MAE, RMSE, R^2_{OOS} и Patton QLIKE (с авто-exp() для log-моделей).
<code>diebold_mariano(...)</code>	<code>models/metrics.py</code>	DM-тест с HAC-стандартной ошибкой (Newey–West, ядро Бартлетта).

4.5 Веб-интерфейс

Веб-интерфейс реализован на микрофреймворке Flask и запускается локально командой `python3 app.py`. При открытии страницы `http://localhost:5000` пользователю доступны три страницы:

1. **Обзор** (/) — временные ряды реализованной волатильности золота и серебра и сводная таблица метрик моделей.
2. **Прогноз волатильности** (/volatility) — интерактивный временной ряд реализованной волатильности с наложением прогноза модели за последние месяцы.
3. **Sentiment-монитор** (/sentiment) — панели с динамикой комбинированного sentiment-индекса, Telegram-score, индекса внимания Google Trends и макроэкономических индикаторов.

Данные загружаются из CSV-файлов при каждом обращении к странице, что обеспечивает автоматическое обновление визуализации после запуска скриптов обновления данных. Стек: Flask 3.0, Plotly 5 (интерактивные графики), Bootstrap 5 (вёрстка).

4.6 Демонстрация системы с точки зрения пользователя

С точки зрения конечного пользователя (аналитика или риск-менеджера) типовой сценарий работы с комплексом выглядит так: пользователь запускает `python3 app.py`, открывает страницу обзора и оценивает текущий уровень и динамику реализованной волатильности по золоту и серебру; затем переходит на страницу прогноза, где визуально сопоставляет фактическую волатильность с прогнозом модели (рисунок 2), и на sentiment-монитор, чтобы соотнести всплески волатильности с изменением информационного фона. Вся навигация осуществляется без перезагрузки данных вручную и без знания внутренней структуры проекта.

На странице прогноза для каждого инструмента строится график логарифма реализованной волатильности: сплошной линией — факт, пунктиром — прогноз XGBoost на тестовой выборке (последние 40% наблюдений). По нему видно, что модель в целом повторяет уровень волатильности, но сглаживает резкие всплески — это совпадает с числовыми результатами раздела 7.



Рис. 2: Страница прогноза веб-интерфейса: сопоставление фактической реализованной волатильности ($\log\text{-RV}$) с прогнозом XGBoost на тестовой выборке для золота (GLDRUB_TOM, сверху) и серебра (SLVRUB_TOM, снизу).

5 Данные

5.1 Котировки драгоценных металлов

Основным источником рыночных данных служит MOEX ISS API — открытый интерфейс Московской биржи. Загружаются дневные OHLCV-данные (цены открытия, максимума, минимума,

закрытия и объём торгов) для четырёх инструментов:

- **GLDRUB_TOM** — золото в рублях, данные с 9 января 2018 г., 2 031 торговый день;
- **SLVRUB_TOM** — серебро в рублях, данные с 9 января 2018 г., 1 926 торговых дней;
- **PLTRUB_TOM** — платина в рублях, данные с 22 октября 2024 г., 346 торговых дней;
- **PLDRUB_TOM** — палладий в рублях, данные с 22 октября 2024 г., 346 торговых дней.

Ввиду ограниченности исторических данных по платине и палладию основной акцент в эмпирическом анализе делается на золоте и серебре.

5.2 Реализованная волатильность

Поскольку внутридневные тиковые данные недоступны, реализованная волатильность считается по дневным OHLC-ценам с помощью range-based оценщиков [8, 13]. Они точнее обычного оценщика по ценам закрытия (Close-to-Close), так как используют ещё максимум и минимум дня.

Оценщик Garman–Klass [8] (используется как основной):

$$\hat{\sigma}_t^2 = \frac{1}{2} (\ln H_t - \ln L_t)^2 - (2 \ln 2 - 1) (\ln C_t - \ln O_t)^2, \quad (4)$$

где O_t, H_t, L_t, C_t — цены открытия, максимума, минимума и закрытия в день t . Эффективность оценщика (4) примерно в 7,4 раза выше, чем у Close-to-Close.

Оценщик Parkinson [13]:

$$\hat{\sigma}_t^2 = \frac{(\ln H_t - \ln L_t)^2}{4 \ln 2}. \quad (5)$$

Аннуализированная волатильность вычисляется как $\hat{\sigma}_t^{\text{ann}} = \sqrt{252 \cdot \hat{\sigma}_t^2}$. Описательные статистики для основных инструментов приведены в таблице 3.

Таблица 3: Описательные статистики аннуализированной волатильности (оценщик Garman–Klass)

Инструмент	N	Среднее	Медиана	Станд. откл.	Минимум	Максимум
GLDRUB_TOM	1 931	0,156	0,115	0,166	0,001	1,659
SLVRUB_TOM	1 635	0,276	0,196	0,270	0,001	2,317

На рисунке 3 представлена динамика аннуализированной реализованной волатильности обоих инструментов за весь период наблюдений. Вертикальная пунктирная линия отмечает 24 февраля 2022 г. — момент резкого скачка волатильности, образующего структурный разрыв в ряду.




Рис. 3: Реализованная волатильность GLDRUB_TOM (золото) и SLVRUB_TOM (серебро), оценщик Garman–Klass, 2018–2026. Жирная линия — скользящее среднее MA(30). Пунктир — 24.02.2022.

5.3 Sentiment и attention признаки

5.3.1 Новостной поток (RSS)

Парсер RSS-лент собирает статьи из шести источников: Коммерсантъ, Ведомости, Интерфакс, ТАСС, РБК и Investing.com. Фильтрация осуществляется по ключевым словам, связанным с металлами, макроэкономикой и геополитикой (54 ключевых слова). Статьи хранятся в `data/sentiment/rss_news.csv`.

5.3.2 Telegram-каналы

Для получения sentiment розничных инвесторов и профессиональных аналитиков используется Telegram API (Telethon). Парсятся 12 активных русскоязычных каналов финансовой тематики: @russianmacro, @bcs_express, @cbrstocks, @markettwits, @ekonomika, @banksta, @alfawealth, @investiciiotpraktika и др. Фильтрация по ключевым словам (металлы, курсы, ставки, макро). Собрано 23 733 релевантных сообщений за период 2018–2026 (2 028 дней). Дневной score вычисляется как взвешенное по просмотрам среднее лексического sentiment; среднее значение — +0,194. Данные хранятся в `data/sentiment/telegram_sentiment.csv`.

5.3.3 GDELT

GDELT (Global Database of Events, Language, and Tone) — открытая база данных, индексирующая мировой новостной поток каждые 15 минут. Используется компонент GKG (Global Knowledge Graph), предоставляющий агрегированные оценки тональности (Tone) новостей по темам. Загружены данные за период 2018–2026 гг. (718 дней с ненулевым покрытием по интересующим темам), среднее количество релевантных записей — 100–150 в день. В дни без прямого покрытия применяется forward fill.

5.3.4 Google Trends

Индекс поисковой активности Google Trends отражает относительный интерес пользователей к теме за период и служит прямой мерой внимания инвесторов [5]. Загружены данные по трём группам запросов: *metals_ru* («золото цена», «купить золото», «серебро цена» и др.), *macro_ru* («ключевая ставка», «инфляция россия», «курс доллара» и др.), *metals_en* («gold price», «silver price» и др.) за период 2018–2026 гг. (3 043 дня), регион — Россия.

5.3.5 Макроэкономические индикаторы

С XML API Банка России загружены: официальные курсы USD/RUB, EUR/RUB и CNY/RUB (ежедневно, 3 060 наблюдений) и история ключевой ставки (решения ЦБ РФ с 2018 г.). Через FRED API дополнительно загружены: цена нефти Brent (DCOILBRENTU, 2 121 наблюдение, среднее \$73,66/барр.), индекс доллара США (DTWEXBGS, 2 094 наблюдения, среднее 118,18), индекс волатильности VIX (VIXCLS, 2 140 наблюдений, среднее 19,65), ставка ФРС (FEDFUNDS) и CPI США (CPIAUCSL).

5.3.6 Объёмы торгов МОЕХ

Дневные объёмы торгов по каждому инструменту выступают в роли прокси внимания инвесторов. Нормализация осуществляется через 30-дневный скользящий z-score с последующим применением sigmoid-функции: $\text{attention_volume}_t = \sigma(z_t) \in [0, 1]$.

5.4 Итоговый датасет

Все источники объединяются агрегатором в файл `daily_sentiment.csv` с дневной частотой за период 2018-01-01 — 2026-05-28 (3 070 дней, 25 признаков). Итоговый вектор включает: sentiment-признаки (RSS, GDELT, Telegram, комбинированный), attention-признаки (Google Trends, объёмы МОЕХ), макроэкономику ЦБ РФ (USD/RUB, EUR/RUB, CNY/RUB, ключевая ставка) и макроэкономику FRED (Brent, DXY, VIX, CPI США, ставка ФРС и их лог-доходности). Доля заполненных значений по всем признакам — 100%. Пропущенные значения заполняются методом forward fill для числовых рядов и нулями для sentiment-переменных в периоды отсутствия данных.

Рисунок 4 демонстрирует динамику ключевых sentiment- и attention-индексов за 2018–2026 гг. Заметно резкое ухудшение комбинированного sentiment в феврале–марте 2022 г. и всплеск

внимания инвесторов (Google Trends) в период санкционного шока, что подтверждает информационную ценность добавленных источников.

Динамика sentiment- и attention-индексов, 2018–2026




Рис. 4: Динамика sentiment- и attention-индексов, 2018–2026. Сверху вниз: комбинированный sentiment (RSS+GDELT+Telegram), Telegram-sentiment, индекс внимания Google Trends (metals_ru). Жирная линия — MA(30). Красный пунктир — 24.02.2022.

6 Методология

6.1 HAR-RV модель

В качестве эконометрического бенчмарка используется модель HAR-RV [4]. Для повышения стационарности и нормальности остатков оцениваются логарифмические спецификации:

HAR-log:

$$\ln RV_{t+1} = \beta_0 + \beta_d \ln RV_t^{(d)} + \beta_w \ln RV_t^{(w)} + \beta_m \ln RV_t^{(m)} + \varepsilon_{t+1}, \quad (6)$$

HAR-log-S (с sentiment):

$$\ln RV_{t+1} = \beta_0 + \beta_d \ln RV_t^{(d)} + \beta_w \ln RV_t^{(w)} + \beta_m \ln RV_t^{(m)} + \beta_s S_{t-1} + \beta_{sw} \bar{S}_{t-1}^{(w)} + \varepsilon_{t+1}, \quad (7)$$

где S_{t-1} — лагированный (на один день) sentiment-индекс, $\bar{S}_{t-1}^{(w)}$ — его пятидневное скользящее среднее. Лаг применяется во избежание data leakage: при прогнозе RV_{t+1} используются только сигналы, известные к концу торгового дня $t - 1$. По умолчанию в качестве S_{t-1} используется взвешенный sentiment_combined (3); в ablation-анализе (раздел 7.3) рассмотрены также отдельные источники.

Оценка проводится методом МНК с поправкой НАС (Newey–West, $\ell = 5$ лагов) для корректного учёта гетероскедастичности и автокорреляции остатков.

6.2 Схема оценки out-of-sample

Для обеспечения реалистичной оценки качества прогнозов применяется процедура расширяющегося окна (expanding window):

1. Первые 60% наблюдений образуют начальную обучающую выборку (не менее 120 наблюдений).
2. На каждом шаге t модель переобучается на всей доступной истории $\{1, \dots, t - 1\}$ и даёт прогноз на шаг t .
3. Прогнозы накапливаются и оцениваются совместно.

6.3 Метрики качества

MAE (Mean Absolute Error):

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |\hat{y}_t - y_t|. \quad (8)$$

RMSE (Root Mean Squared Error):

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (\hat{y}_t - y_t)^2}. \quad (9)$$

QLIKE [14] — робастная метрика для волатильности:

$$\text{QLIKE} = \frac{1}{T} \sum_{t=1}^T \left(\frac{RV_t}{\hat{\sigma}_t^2} - \ln \frac{RV_t}{\hat{\sigma}_t^2} - 1 \right). \quad (10)$$

R_{OOS}^2 [9] — out-of-sample R^2 относительно бенчмарка исторического среднего:

$$R_{\text{OOS}}^2 = 1 - \frac{\text{MSE}_{\text{model}}}{\text{MSE}_{\text{bench}}}, \quad (11)$$

где $\text{MSE}_{\text{bench}} = T^{-1} \sum_t (y_t - \bar{y})^2$. Положительный R_{OOS}^2 означает, что модель превосходит наивный прогноз историческим средним.

Тест Диболда–Мариано [6] применяется для проверки статистической значимости различий между прогнозами двух моделей. Для пары моделей M_1, M_2 строится ряд разностей функций потерь $d_t = L(e_t^{(1)}) - L(e_t^{(2)})$ и тестируется $H_0 : \mathbb{E}[d_t] = 0$ против двусторонней альтернативы. Статистика

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \xrightarrow{d} \mathcal{N}(0, 1), \quad (12)$$

где $\widehat{\text{Var}}(\bar{d})$ — оценка долгосрочной дисперсии по Newey–West с ядром Бартлетта. В работе тестируются три типа потерь: SE ($d_t = (y_t - \hat{y}_t^{(1)})^2 - (y_t - \hat{y}_t^{(2)})^2$), АЕ (абсолютное отклонение) и QLIKE (Patton).

6.4 XGBoost

Модель градиентного бустинга XGBoost [3] обучается на расширенном наборе признаков, включающем: HAR-лаги ($RV^{(d)}, RV^{(w)}, RV^{(m)}$), дополнительные лаги RV_{t-k} ($k = 2, \dots, 5$), и sentiment/attention/macro-признаки из `daily_sentiment.csv`. Гиперпараметры: глубина деревьев 4, скорость обучения 0,05, 300 деревьев, L_1 -регуляризация 0,1. Разбиение обучения/теста — 60/40 по времени без перемешивания.

6.5 kNN на пространстве информационных состояний

По методологии Halousková и Lyócsa [10] реализован kNN-прогнозировщик на основе поиска исторически похожих информационных состояний. Для каждого тестового дня t строится вектор состояния:

$$\mathbf{z}_t = \underbrace{[rv_t^{(d)}, rv_t^{(w)}, rv_t^{(m)}]}_{\text{HAR-блок}}, \underbrace{[s_1, \dots, s_6]}_{\text{sentiment-блок}},$$

где $s_1, \dots, s_6$ — нормированные sentiment/attention-переменные (RSS, GDELT, Telegram, Google Trends, объём торгов, combined). Сходство между днём t и историческим днём $s < t$ вычисляется как сумма *обратно-расстоянных* (inverse-distance) ядер по HAR- и sentiment-блокам отдельно:

$$\text{sim}(t, s) = \frac{1}{1 + \|\mathbf{h}_t - \mathbf{h}_s\|_2} + \frac{w_s}{1 + \|\mathbf{s}_{t-1} - \mathbf{s}_{s-1}\|_2}, \quad w_s = 1, 0.$$

Sentiment-вектор $\mathbf{s}$ берётся с лагом 1 (как и в HAR-log-S), что обеспечивает консистентность всех моделей по графику доступной информации. Прогноз — взвешенное среднее реализованной волатильности k ближайших соседей:

$$\widehat{\ln RV}_{t+1} = \sum_{i \in \mathcal{N}_k(t)} w_i \cdot \ln RV_{i+1}, \quad w_i = \frac{\text{sim}(t, i)}{\sum_{j \in \mathcal{N}_k(t)} \text{sim}(t, j)}.$$

Оптимальное число соседей k^* подбирается на обучающей выборке. После устранения leakage и унификации QLIKE-метрики оптимумы сместились: $k^* = 75$ для GLDRUB_TOM и $k^* = 30$ для SLVRUB_TOM.

6.6 Вычислительная сложность и обоснование оптимальности

Так как проект программный, итоговую модель важно выбирать не только по точности, но и по вычислительной стоимости в режиме расширяющегося окна. Пусть T — число шагов теста, N — размер обучающей истории на текущем шаге, p — число признаков, m — размерность вектора состояния, K и d — число и глубина деревьев бустинга. Сложность моделей приведена в таблице 4.

Таблица 4: Вычислительная сложность моделей в режиме расширяющегося окна

Модель	Переобучение на шаг	Прогноз на шаг
HAR-log / HAR-log-S	$O(Np^2 + p^3)$	$O(p)$
XGBoost	$O(K d N \log N)$	$O(K d)$
kNN (информ. состояния)	— (без обучения)	$O(Nm)$

HAR-модели сводятся к МНК с малым числом признаков ($p \leq 6$), поэтому переобучение на каждом шаге занимает доли секунды, и суммарная стоимость $O(TNp^2)$ — наименьшая среди всех моделей. XGBoost требует заметно больше вычислений из-за построения деревьев и подбора гиперпараметров. kNN не обучается, но каждый прогноз требует сравнения со всей историей, что даёт стоимость $O(TNm)$ — это самая дорогая модель на этапе прогноза.

Если сравнить это с результатами раздела 7, видно, что HAR-log-S — лучший выбор: она даёт лучшее качество для золота, считается быстрее всех и сохраняет понятные коэффициенты. Более дорогие XGBoost и kNN при этом не выигрывают по качеству ни на одном инструменте.

7 Результаты

7.1 HAR-RV бенчмарк

Все эконометрические и ML-модели в данной работе используют единую реализацию метрик качества (`src/models/metrics.py`) с канонической формулой QLIKE по Patton [14]. Это обеспечивает корректность попарного сравнения, ранее затруднённого расхождением формул в разных модельных модулях. Дополнительно все sentiment- и attention-признаки используются с лагом 1 (значение, известное к концу предыдущего торгового дня), что исключает потенциальный data leakage при прогнозе RV_t .

Результаты оценки HAR-log модели на золоте (GLDRUB_TOM) методом расширяющегося окна (обучение 60%, тест 40%, $n_{\text{test}} = 773$ дня для золота и $n_{\text{test}} = 654$ для серебра) представлены в таблице 5.

Таблица 5: Метрики HAR-log модели (expanding window OOS)

Инструмент	Спецификация	MAE	RMSE	R_{OOS}^2	QLIKE
GLDRUB_TOM	HAR-log	0,674	0,869	0,177	0,628
SLVRUB_TOM	HAR-log	0,838	1,060	0,377	0,979

Модель HAR-log демонстрирует положительный R_{OOS}^2 для обоих инструментов: 0,177 для золота и 0,377 для серебра, что означает превосходство над наивным прогнозом средним. Оценка

МНК на полной выборке даёт $R^2 = 0,606$ (золото) и $0,550$ (серебро), что типично для HAR-моделей на дневных данных.

Для золота (GLDRUB_TOM, $n = 1\,931$): $\hat{\alpha} = -0,524$, $\hat{\beta}_d = 0,143$, $\hat{\beta}_w = 0,353$, $\hat{\beta}_m = 0,451$. Для серебра (SLVRUB_TOM, $n = 1\,635$): $\hat{\alpha} = -1,039$, $\hat{\beta}_d = 0,171$, $\hat{\beta}_w = 0,411$, $\hat{\beta}_m = 0,296$. Выполнение неравенства $\hat{\beta}_m > \hat{\beta}_w > \hat{\beta}_d$ для золота соответствует теоретическим предсказаниям HAR-модели об убывании скорости адаптации участников с более длинным горизонтом.

7.2 HAR-log-S с многоисточниковым sentiment-вектором

Модель HAR-log-S расширяет HAR-log дневным и недельным значениями взвешенного индекса S_t^{comb} (3), объединяющего RSS-, GDELT- и Telegram-сигналы. В таблице 6 приведено сравнение спецификации со включённым sentiment с базовой HAR-log.

Таблица 6: HAR-log vs HAR-log-S (sentiment_combined, лаг 1)					
Инструмент	Модель	MAE	RMSE	R_{OOS}^2	QLIKE
GLDRUB_TOM	HAR-log	0,674	0,869	0,177	0,628
GLDRUB_TOM	HAR-log-S	0,672	0,868	0,180	0,626
SLVRUB_TOM	HAR-log	0,838	1,060	0,377	0,979
SLVRUB_TOM	HAR-log-S	0,834	1,060	0,376	1,022

На золоте HAR-log-S улучшает все четыре метрики, хотя прирост невелик (MAE снижается на 0,3%, R_{OOS}^2 растёт с 0,177 до 0,180). На серебре наблюдается смешанный эффект: MAE снижается с 0,838 до 0,834, однако QLIKE ухудшается с 0,979 до 1,022, а R_{OOS}^2 остаётся практически неизменным. Тест Диболда–Мариано [6] (раздел 7.6) показывает, что улучшение по MAE значительно лишь на уровне 10% ($p = 0,078$ для золота, $p = 0,070$ для серебра), а на серебре по QLIKE sentiment даже статистически значимо *ухудшает* прогноз ($p < 0,001$). Это согласуется с интерпретацией: добавление шумного многоисточникового sentiment может незначительно улучшать центр распределения ошибки (MAE), но повышать дисперсию по краям (QLIKE).

7.3 Ablation: вклад отдельных sentiment-источников

Для понимания роли каждого источника проведено ablation-исследование HAR-log-S с подстановкой одного источника вместо взвешенного индекса (таблица 7).

Ключевые наблюдения:

1. **RSS даёт нулевой вклад.** Замена на чистый RSS-индекс приводит к метрикам, побитово совпадающим с HAR-log без sentiment. Это указывает, что в текущей версии `rss_news.csv` NLP-агрегация даёт постоянное (нулевое) значение для большинства торговых дней, что нейтрализует регрессор.
2. **Для золота сильнейший источник — взвешенный комбинированный индекс (RSS+GDELT+Telegram),** что подтверждает гипотезу о диверсификации источников.

Таблица 7: HAR-log-S ablation: вклад каждого sentiment/attention-источника

Инструмент	Источник S_t	MAE	RMSE	R^2_{OOS}	QLIKE
GLDRUB_TOM	HAR-log (без S)	0,6744	0,8694	0,1773	0,6281
GLDRUB_TOM	sentiment_combined	0,6723	0,8682	0,1795	0,6261
GLDRUB_TOM	sentiment_score (RSS)	0,6744	0,8694	0,1773	0,6281
GLDRUB_TOM	sentiment_gdelt	0,6756	0,8700	0,1760	0,6267
GLDRUB_TOM	tg_score (Telegram)	0,6725	0,8689	0,1781	0,6364
GLDRUB_TOM	attention_google	0,6878	0,8815	0,1541	0,5905
SLVRUB_TOM	HAR-log (без S)	0,8383	1,0596	0,3765	0,9790
SLVRUB_TOM	sentiment_combined	0,8342	1,0599	0,3762	1,0216
SLVRUB_TOM	sentiment_score (RSS)	0,8383	1,0596	0,3765	0,9790
SLVRUB_TOM	sentiment_gdelt	0,8400	1,0610	0,3749	0,9765
SLVRUB_TOM	tg_score (Telegram)	0,8352	1,0621	0,3736	1,0364
SLVRUB_TOM	attention_google	0,8466	1,0585	0,3778	0,9729

3. Для серебра доминирует attention_google — индекс поисковой активности Google Trends, дающий лучший R^2_{OOS} и QLIKE на этом инструменте. Это согласуется с теоретической работой Да, Энгельберг и Гао [5] об индексе внимания розничных инвесторов как самостоятельной предиктивной переменной, особенно значимой для активов с высокой долей розничного спроса.
4. Telegram-индекс полезен по MAE на обоих инструментах, но не улучшает QLIKE.

7.4 kNN на пространстве информационных состояний

По методологии Halousková и Lyócsa [10] реализован kNN-прогнозировщик: для каждого тестового дня t находятся k исторически ближайших дней в нормированном пространстве признаков (HAR-лаги + sentiment-вектор из 6 переменных). Сходство вычисляется как обратное расстояние (inverse-distance kernel):

$$\text{sim}(t, s) = \frac{1}{1 + \|\mathbf{h}_t - \mathbf{h}_s\|} + \frac{w_s}{1 + \|\mathbf{s}_t - \mathbf{s}_s\|}, \quad w_s = 1, 0,$$

прогноз — взвешенное среднее log RV соседей. Оптимальное k подбирается по обучающей выборке с использованием тех же sentiment-данных с лагом 1. После исправления QLIKE-метрики и фикса leakage оптимумы сместились в сторону больших значений: $k^* = 75$ (GLDRUB_TOM) и $k^* = 30$ (SLVRUB_TOM). Метрики приведены в таблице 8.

Таблица 8: kNN с оптимальным k (после фикса QLIKE и sentiment-лага)

Инструмент	Модель	MAE	RMSE	R^2_{OOS}	QLIKE
GLDRUB_TOM	kNN ($k = 75$)	0,671	0,877	0,163	0,683
SLVRUB_TOM	kNN ($k = 30$)	0,859	1,086	0,345	1,167

7.5 XGBoost

Модель градиентного бустинга XGBoost [3] обучается на расширенном наборе признаков: HAR-лаги, дополнительные лаги RV_{t-k} ($k = 2, \dots, 5$) и sentiment-вектор (sentiment_combined,

sentiment_gdelt, tg_score, attention_google) с лагом 1 для совместимости с настройкой HAR-log-S. Гиперпараметры: глубина деревьев 4, скорость обучения 0,05, 300 деревьев, L_1 -регуляризация 0,1. Разбиение обучения/теста — 60/40 по времени без перемешивания (в отличие от expanding-window для HAR и kNN, что отдельно отмечено в обсуждении методологии).

Результаты XGBoost на корректно подготовленных данных (таблица 9, требуется запуск `python3 -m src.models.ml_models`; библиотека `xgboost` устанавливается отдельно):

Таблица 9: XGBoost на расширенном наборе признаков с лагированным sentiment

Инструмент	Модель	MAE	RMSE	R^2_{OOS}	QLIKE
GLDRUB_TOM	XGBoost	0,725	0,924	0,070	0,627
SLVRUB_TOM	XGBoost	0,879	1,119	0,305	1,237

Анализ важности признаков (feature importance) по методу средней прибыли деревьев показывает доминирование HAR-лагов над sentiment-признаками. Для GLDRUB_TOM топ-5 признаков — `rv_m` (0,387), `rv_w` (0,233), `rv_d` (0,144), `rv_lag_2` (0,079), `rv_lag_4` (0,054). Для SLVRUB_TOM доминирует недельная компонента: `rv_w` (0,514), `rv_d` (0,117), `rv_m` (0,117), `rv_lag_4` (0,068), `rv_lag_2` (0,065). Во всех случаях sentiment-признаки занимают позиции 6–13, что согласуется с результатами Halousková и Lúcsa [10], показавших умеренный, но статистически значимый вклад attention-вектора. Полная диаграмма топ-15 признаков для обоих инструментов представлена на рисунке 5.




Рис. 5: Важность признаков XGBoost (gain, нормировано). Слева — GLDRUB_TOM (золото), справа — SLVRUB_TOM (серебро). HAR-лаги доминируют; sentiment- и макро-признаки занимают нижние позиции.

На рисунке 6 показан прогноз модели XGBoost в сравнении с фактическими значениями логарифмической реализованной волатильности на тестовой выборке (40% наблюдений).

XGBoost: прогноз vs факт (тестовая выборка)




Рис. 6: XGBoost: прогноз vs факт (log-RV) на тестовой выборке. Сверху — GLDRUB_TOM, снизу — SLVRUB_TOM.

7.6 Сравнительный анализ и тест Диболда–Мариано

Сводные результаты всех моделей представлены в таблице 10.

Таблица 10: Сравнение всех моделей (после фиксов: общая Patton QLIKE, лаг sentiment 1)

Инструмент	Модель	MAE	RMSE	R^2_{OOS}	QLIKE
GLDRUB_TOM	HAR-log	0,674	0,869	0,177	0,628
GLDRUB_TOM	HAR-log-S	0,672	0,868	0,180	0,626
GLDRUB_TOM	XGBoost	0,725	0,924	0,070	0,627
GLDRUB_TOM	kNN ($k = 75$)	0,671	0,877	0,163	0,683
SLVRUB_TOM	HAR-log	0,838	1,060	0,377	0,979
SLVRUB_TOM	HAR-log-S	0,834	1,060	0,376	1,022
SLVRUB_TOM	XGBoost	0,879	1,119	0,305	1,237
SLVRUB_TOM	kNN ($k = 30$)	0,859	1,086	0,345	1,167

Для оценки статистической значимости различий между моделями применяется тест Диболда–Мариано [6] с поправкой HAC (Newey–West, ядро Бартлетта, 1 лаг). Тестируется нулевая

гипотеза равенства ожидаемых функций потерь: $H_0 : \mathbb{E}[L(e_1) - L(e_2)] = 0$. В таблице 11 приведены попарные результаты; знак *modell better* означает, что первая модель имеет статистически значимо меньшую функцию потерь.

Таблица 11: Тест Диболда–Мариано: попарные сравнения моделей. *** $p < 0,01$; ** $p < 0,05$; * $p < 0,10$

Инструмент	Сравнение (M1 vs M2)	Потери	DM-статистика	p -value	Заключение
GLDRUB_TOM	HAR-log vs HAR-log-S	SE	+0,97	0,33	нет различий
GLDRUB_TOM	HAR-log vs HAR-log-S	AE	+1,76	0,08*	M2 лучше
GLDRUB_TOM	HAR-log vs HAR-log-S	QLIKE	+0,62	0,53	нет различий
GLDRUB_TOM	HAR-log vs kNN	SE	−0,95	0,34	нет различий
GLDRUB_TOM	HAR-log vs kNN	QLIKE	−2,41	0,02**	M1 лучше
GLDRUB_TOM	HAR-log-S vs kNN	QLIKE	−2,38	0,02**	M1 лучше
SLVRUB_TOM	HAR-log vs HAR-log-S	SE	−0,13	0,90	нет различий
SLVRUB_TOM	HAR-log vs HAR-log-S	AE	+1,81	0,07*	M2 лучше
SLVRUB_TOM	HAR-log vs HAR-log-S	QLIKE	−3,83	< 0,001***	M1 лучше
SLVRUB_TOM	HAR-log vs kNN	SE	−1,83	0,07*	M1 лучше
SLVRUB_TOM	HAR-log vs kNN	QLIKE	−2,84	0,005***	M1 лучше
SLVRUB_TOM	HAR-log-S vs kNN	AE	−2,04	0,04**	M1 лучше
SLVRUB_TOM	HAR-log-S vs kNN	QLIKE	−2,27	0,02**	M1 лучше

7.7 Главные выводы

1. **Sentiment даёт ограниченный вклад.** Расширенный HAR-log-S с комбинированным sentiment-индексом улучшает MAE на обоих инструментах статистически значимо лишь на уровне 10% ($p \approx 0,07$ – $0,08$). По QLIKE улучшение наблюдается только на золоте и не значимо; на серебре sentiment даже *ухудшает* QLIKE значимо ($p < 0,001$).
2. **Лучший единичный sentiment-источник зависит от инструмента.** Для золота это взвешенный sentiment_combined, для серебра — attention_google (Google Trends), что согласуется с теорией Да–Энгельберга–Гао о Google-индексе как самостоятельной мере внимания розничных инвесторов.
3. **kNN не превосходит HAR после корректной настройки.** После унификации формулы QLIKE и устранения leakage по sentiment kNN(HAR+sentiment) проигрывает HAR-log/HAR-log-S по R^2_{OOS} и QLIKE на обоих инструментах; по MAE результат близок к ничьей. Полученный итог отличается от предыдущих внутренних расчётов по проекту, где kNN формально лидировал на золоте — анализ источников расхождения (раздел 7.6) показывает, что прежнее преимущество было артефактом несовместимых определений QLIKE и одновременности sentiment с целевой переменной.
4. **XGBoost существенно уступает HAR.** Это типично для задач прогнозирования волатильности дневной частоты: нелинейное усложнение модели не компенсирует шум множества

дополнительных признаков при ограниченном размере выборки.

7.8 Ограничения и направления развития

Текущие результаты получены при частично заполненном sentiment-векторе: данные GDELT охватывают ≈ 718 дней с ненулевым покрытием (остальные дни заполнены методом forward fill), NLP-агрегация RSS-новостей даёт устойчиво нулевой sentiment для большинства дней, что объясняет нулевой вклад этого источника в ablation (таблица 7). Расширение NLP-покрытия RSS, увеличение Telegram-архива до сопоставимой плотности и подключение дополнительных макро-сигналов (данные ЦБ РФ по объёмам сделок СВОП, индексы геополитической неопределённости GPR) являются естественными направлениями дальнейшей работы.

8 Тестирование программного комплекса

8.1 Стратегия тестирования

Тестирование программного комплекса проводилось на трёх уровнях: *модульном* (проверка корректности отдельных функций), *интеграционном* (проверка взаимодействия модулей через файловый интерфейс) и *системном* (проверка сквозного выполнения полного пайплайна).

8.2 Модульные тесты

8.2.1 Тестирование вычисления реализованной волатильности

Для оценщиков Garman–Klass и Parkinson проверялись:

1. **Граничные случаи.** При $H_t = L_t = O_t = C_t$ (свеча без движения) оба оценщика возвращают $\hat{\sigma}_t^2 = 0$.
2. **Масштабирование.** При умножении всех цен на константу $k > 0$ логарифмическая волатильность не изменяется: $\hat{\sigma}^2(kO, kH, kL, kC) = \hat{\sigma}^2(O, H, L, C)$.
3. **Воспроизводимость.** Повторный запуск `compute_rv.py` на тех же данных даёт побайтово идентичный CSV-файл.
4. **Сравнение оценщиков.** На синтетических данных, сгенерированных из геометрического броуновского движения с известной дисперсией $\sigma^2 = 0,04$, среднее значение оценщика Garman–Klass отклоняется от истинного не более чем на 5% при $n > 250$ наблюдений.

8.2.2 Тестирование парсеров

Каждый парсер тестировался следующим образом:

- **download_moex.py:** запрос на однодневный период возвращает ровно одну строку OHLCV; колонки `open`, `high`, `low`, `close`, `volume` присутствуют и имеют корректные типы данных (`float64`).
- **parse_cbr.py:** курс USD/RUB на 01.01.2022 соответствует официальному значению ЦБ РФ (74,29 руб.) с точностью до копейки.
- **parse_fred.py:** значение VIX на 24.02.2022 превышает 30,0 (проверка корректности загрузки данных о волатильности в период шока).
- **aggregate_sentiment.py:** результирующий датафрейм содержит ровно 25 признаков; доля NaN-значений равна 0 после `forward fill`.

8.2.3 Тестирование HAR-модели

1. **Детерминизм.** Модель HAR-log при двух последовательных запусках на одних данных возвращает идентичные коэффициенты.
2. **Структура предсказания.** При `expanding window` с начальным окном 120 дней длина вектора прогнозов совпадает с числом тестовых наблюдений.
3. **Знаки коэффициентов.** На реальных данных GLDRUB_TOM все три коэффициента $\hat{\beta}_d, \hat{\beta}_w, \hat{\beta}_m > 0$, что соответствует теоретическим ожиданиям модели HAR-RV.

8.2.4 Тестирование XGBoost

1. **Воспроизводимость.** Фиксация `random_state=42` обеспечивает идентичные метрики при повторных запусках.
2. **Отсутствие утечки данных.** Разбиение 60/40 производится строго по времени: ни один тестовый индекс не присутствует в обучающей выборке.
3. **Корректность метрик.** Значение R_{OOS}^2 вычисляется относительно исторического среднего обучающей выборки, а не тестовой (проверка реализации формулы Goyal–Welch).

8.3 Интеграционное тестирование

Интеграционный тест запускает сквозной пайплайн на коротком подпериоде данных (2023-01-01 — 2023-12-31):

1. **download_moex.py** → GLDRUB_TOM_1d.csv (248 строк)
2. **compute_rv.py** → rv_features.csv (246 строк, 10 признаков)
3. **aggregate_sentiment.py** → daily_sentiment.csv (365 строк, 25 признаков)
4. **ml_models.py** → GLDRUB_TOM_xgb_predictions.csv

Тест проходит успешно, если:

- ни один из шагов не завершился с исключением;
- все выходные файлы созданы с ненулевым числом строк;
- R^2_{OOS} XGBoost на 2023 г. превышает 0,0 (модель превосходит наивный прогноз историческим средним).

8.4 Системное тестирование

Полный цикл обновления данных и переобучения моделей тестировался на периоде 2018–2026 (производительность):

- Загрузка котировок MOEX (4 инструмента): ≈ 45 сек.
- Загрузка CBR + FRED: ≈ 30 сек.
- Загрузка GDELT (инкрементальный режим, последние 30 дней): ≈ 5 мин.
- Агрегация sentiment: < 10 сек.
- Обучение XGBoost (expanding window, 2 инструмента): ≈ 4 мин.
- Запуск Flask-сервера: < 5 сек.

Суммарное время полного цикла составило ≈ 12 минут, что удовлетворяет нефункциональному требованию (не более 30 минут, раздел 2).

8.5 Объёмные характеристики кода и данных

Согласно требованиям к экспериментальной части программного проекта, ниже приведены объёмные характеристики разработанного программного комплекса и используемых данных (таблицы 12 и 13).

Таблица 12: Объём программного кода по подсистемам	
Подсистема (директория)	Строк кода
src/data/ (7 парсеров + агрегатор)	2 378
src/models/ (HAR, XGBoost, kNN, RV, метрики)	1 440
src/nlp/ (обработка текстов)	432
src/web/ (Flask-роуты, шаблоны)	451
app.py (точка входа дашборда)	516
Всего Python-кода	5 217

Суммарный объём исходного кода — ≈ 309 KB.

Прогнозы моделей в проекте сгенерировали 15 артефактов в data/processed/har_results/ (прогнозы и метрики для трёх спецификаций каждого из двух инструментов плюс файлы ablation)

Таблица 13: Объём входных и промежуточных датасетов

Файл	Размер	Содержание
data/processed/metals_1d_panel.csv	310 KB	OHLCV 4-х инструментов
data/processed/rv_features.csv	657 KB	RV + HAR-лаги (4 238 строк)
data/sentiment/daily_sentiment.csv	737 KB	25 признаков $\times$ 3 070 дней
data/sentiment/cbr_data.csv	211 KB	Курсы и ставка ЦБ РФ
data/sentiment/fred_macro.csv	336 KB	Brent, VIX, DXY, CPI, FED
data/sentiment/google_trends.csv	246 KB	3 группы запросов
data/sentiment/gdelt_sentiment.csv	97 KB	Tone из GDELT GKG
data/sentiment/rss_news.csv	66 KB	RSS 6 источников
data/sentiment/telegram_news.csv	19 MB	23 733 сырых сообщений
data/sentiment/telegram_sentiment.csv	59 KB	Дневная агрегация Telegram

и 6 артефактов в data/processed/ml_results/ (XGBoost и kNN для GLDRUB/SLVRUB плюс сводные таблицы). Сводная таблица попарного DM-теста (12 пар $\times$ 3 типа потерь) сохраняется в data/processed/dm_test_summary.csv.

8.6 Валидация данных

Помимо функционального тестирования проводилась автоматическая валидация качества данных:

1. **Монотонность цен:** $H_t \geq \max(O_t, C_t)$ и $L_t \leq \min(O_t, C_t)$ для каждой свечи. Нарушений не обнаружено.
2. **Временной охват:** непрерывность дат в daily_sentiment.csv (отсутствие пропущенных календарных дней) — проверка пройдена.
3. **Заполненность признаков:** доля NaN по каждому из 25 признаков равна 0 % после агрегации.
4. **Диапазон sentiment:** все значения sentiment_combined $\in [-1, 0; 1, 0]$.

9 Заключение

В настоящей работе разработан программный комплекс для прогнозирования реализованной волатильности рынка драгоценных металлов Московской биржи с учётом настроений и внимания инвесторов.

Основные результаты:

1. Собран и обработан панельный датасет дневных котировок золота (GLDRUB_TOM) и серебра (SLVRUB_TOM) за период 2018–2026 гг. (1 931 и 1 635 торговых дней соответственно). Реализованная волатильность вычислена оценщиком Garman–Klass.
2. Сформирован многоисточниковый вектор sentiment/attention/macro (25 признаков): новостной поток RSS (6 источников), GDELT (718 дней с покрытием за 2018–2026), Telegram (12 каналов, 23 733 сообщений, 2 028 дней), Google Trends (3 043 дня), курсы валют и ключевая

ставка ЦБ РФ, объёмы торгов MOEX, макроэкономические данные FRED (Brent, DXY, VIX, CPI США, ставка ФРС). Все источники автоматически обновляются через реализованные парсеры.

3. Эконометрический бенчмарк HAR-log показал устойчивые результаты: $R_{OOS}^2 = 0,177$ (золото) и $0,377$ (серебро). Коэффициенты $\hat{\beta}_m > \hat{\beta}_w > \hat{\beta}_d > 0$ соответствуют теоретическим предсказаниям модели для золота.
4. Расширенная спецификация HAR-log-S с лагированным взвешенным sentiment-индексом улучшает MAE на обоих инструментах ($0,674 \rightarrow 0,672$ для золота, $0,838 \rightarrow 0,834$ для серебра), однако улучшение значимо лишь на уровне 10% по тесту Диболда–Мариано (раздел 7.6). Ablation-анализ показал, что вклад различных sentiment-источников различается между инструментами: для золота сильнейший источник — взвешенный sentiment_combined, для серебра — attention_google (Google Trends). Это согласуется с теорией Да–Энгельберга–Гао [5] об индексе поисковой активности как самостоятельной мере внимания розничных инвесторов.
5. Модель XGBoost с расширенным sentiment-вектором даёт $R_{OOS}^2 = 0,070$ (золото) и $0,305$ (серебро), уступая HAR-log/HAR-log-S на обоих инструментах.
6. kNN-модель на пространстве HAR+sentiment-признаков (Halousková & Lyócsa, [10]; $k^* = 75$ для золота, $k^* = 30$ для серебра) после устранения потенциальной утечки данных (лаг sentiment 1) и унификации формулы QLIKE не превзошла HAR-log/HAR-log-S по R_{OOS}^2 и QLIKE на обоих инструментах. Этот негативный результат, выявленный в ходе работы, важен сам по себе: он показывает, что прежние внутренние оценки преимущества kNN были артефактом несовместимых определений метрик и одновременности sentiment с целевой переменной.
7. Реализован веб-интерфейс на Flask с тремя страницами (обзор, прогноз волатильности, sentiment-монитор) для интерактивной визуализации реализованной волатильности, прогноза модели и динамики sentiment/attention-индексов.

Методологический вклад работы: показано, что для строгого сравнения моделей прогнозирования волатильности необходимо одновременное соблюдение двух условий — единой формулы QLIKE и согласованного временного лага всех экзогенных признаков относительно целевой переменной. Нарушение любого из условий может привести к иллюзорному преимуществу более сложных моделей. Для проекта подготовлен единый модуль метрик (src/models/metrics.py) с канонической Patton QLIKE и тестом Диболда–Мариано, который может быть переиспользован в дальнейших работах. Основной практический итог проекта — не отдельная модель, а законченный комплекс: сбор семи источников (MOEX ISS, GDELT, Google Trends, Telegram, RSS, ЦБ РФ, FRED), приведение их к единому календарю торгов, организация оценки на расширяющемся окне без утечек и веб-визуализация результатов. Именно объём инженерной части (раздел 8.5) и составляет основную сложность работы.

Направления дальнейшей работы:

- Расширение NLP-покрытия RSS-новостей: текущая реализация даёт устойчиво нулевой sentiment для большинства торговых дней, что нейтрализует регрессор в ablation (таблица 7).
- Подключение дополнительных макро-сигналов (объёмы СВОП-сделок ЦБ РФ, индексы геополитической неопределённости GPR).
- Применение методологии к платине и палладию по мере накопления выборки до уровня, достаточного для надёжной оценки expanding-window OOS (в текущем датасете 346 наблюдений на инструмент).
- Распространение HAR-log-S на более длинные горизонты прогнозирования (5, 22 дня) с агрегацией sentiment-вектора по соответствующим окнам.

10 Описание применения генеративной модели

Название модели. Claude (разработчик — Anthropic), семейство больших языковых моделей.

Адрес в сети «Интернет». <https://claude.ai> (разработчик — <https://www.anthropic.com>).

Цели применения. Генеративная модель применялась как вспомогательный инструмент (ассистент программиста и редактор), но не как источник идей или результатов работы. Основные цели — ускорение рутинных операций написания и отладки кода, техническая редактура и оформление текста отчёта в $\text{\LaTeX}$, а также дополнительная проверка корректности экспериментов.

Способ применения. Применение носило характер диалогового ассистирования по конкретным задачам и охватывало:

- написание и отладку отдельных фрагментов программного кода (парсеры источников данных, реализации моделей HAR, XGBoost и kNN, модуль метрик, веб-интерфейс) с последующей проверкой, тестированием и адаптацией кода автором;
- техническую редактуру и оформление текста отчёта в $\text{\LaTeX}$;
- дополнительную проверку экспериментальной части, в ходе которой были подтверждены и устранены методологические неточности ранних версий кода (несогласованность формул QLIKE между моделями, утечка данных из-за одновременности sentiment-признаков с целевой переменной).

Мой собственный вклад. Постановку задачи и формулировку цели, выбор предметной области и источников данных, проектирование архитектуры программного комплекса, выбор и обоснование моделей и метрик, организацию схемы оценивания, фактический сбор данных, запуск всех вычислительных экспериментов, интерпретацию результатов и все выводы работы я выполнил самостоятельно. Все приведённые в работе численные показатели получены в результате моих реальных вычислительных экспериментов на собранных данных. Сгенерированные моделью фрагменты кода и текста я рассматривал как черновой материал: проверял, тестировал, корректировал

и принимал их под свою ответственность, неся полную ответственность за итоговое содержание работы.

Список использованных источников

- [1] Araci, D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models / D. Araci // arXiv preprint, arXiv:1908.10063. — 2019. — URL: <https://arxiv.org/abs/1908.10063> (дата обращения: 28.05.2026).
- [2] Bollerslev, T. Generalized Autoregressive Conditional Heteroskedasticity / T. Bollerslev // Journal of Econometrics. — 1986. — Vol. 31, No. 3. — P. 307–327. — DOI: [10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1).
- [3] Chen, T. XGBoost: A Scalable Tree Boosting System / T. Chen, C. Guestrin // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — 2016. — P. 785–794. — DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [4] Corsi, F. A Simple Approximate Long-Memory Model of Realized Volatility / F. Corsi // Journal of Financial Econometrics. — 2009. — Vol. 7, No. 2. — P. 174–196. — DOI: [10.1093/jjfinc/nbp001](https://doi.org/10.1093/jjfinc/nbp001).
- [5] Da, Z. In Search of Attention / Z. Da, J. Engelberg, P. Gao // Journal of Finance. — 2011. — Vol. 66, No. 5. — P. 1461–1499. — DOI: [10.1111/j.1540-6261.2011.01679.x](https://doi.org/10.1111/j.1540-6261.2011.01679.x).
- [6] Diebold, F. X. Comparing Predictive Accuracy / F. X. Diebold, R. S. Mariano // Journal of Business & Economic Statistics. — 1995. — Vol. 13, No. 3. — P. 253–263. — DOI: [10.1080/07350015.1995.10524599](https://doi.org/10.1080/07350015.1995.10524599).
- [7] Engle, R. F. Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation / R. F. Engle // Econometrica. — 1982. — Vol. 50, No. 4. — P. 987–1007. — DOI: [10.2307/1912773](https://doi.org/10.2307/1912773).
- [8] Garman, M. B. On the Estimation of Security Price Volatilities from Historical Data / M. B. Garman, M. J. Klass // Journal of Business. — 1980. — Vol. 53, No. 1. — P. 67–78. — DOI: [10.1086/296072](https://doi.org/10.1086/296072).
- [9] Goyal, A. A Comprehensive Look at the Empirical Performance of Equity Premium Prediction / A. Goyal, I. Welch // Review of Financial Studies. — 2008. — Vol. 21, No. 4. — P. 1455–1508. — DOI: [10.1093/rfs/hhm014](https://doi.org/10.1093/rfs/hhm014).
- [10] Halousková, M. Forecasting U.S. Equity Market Volatility with Attention and Sentiment to the Economy [Электронный ресурс] / M. Halousková, Š. Lyócsa // arXiv preprint, arXiv:2503.19767. — 2025. — URL: <https://arxiv.org/abs/2503.19767> (дата обращения: 28.05.2026).
- [11] Hochreiter, S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // Neural Computation. — 1997. — Vol. 9, No. 8. — P. 1735–1780. — DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- [12] Liu, X.-Y. FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance / X.-Y. Liu, H. Yang, Q. Chen [et al.] // NeurIPS 2020 Deep RL Workshop. — 2021. — URL: <https://arxiv.org/abs/2011.09607> (дата обращения: 28.05.2026).

- [13] Parkinson, M. The Extreme Value Method for Estimating the Variance of the Rate of Return / M. Parkinson // Journal of Business. — 1980. — Vol. 53, No. 1. — P. 61–65. — DOI: [10.1086/296071](https://doi.org/10.1086/296071).
- [14] Patton, A. J. Volatility Forecast Comparison Using Imperfect Volatility Proxies / A. J. Patton // Journal of Econometrics. — 2011. — Vol. 160, No. 1. — P. 246–256. — DOI: [10.1016/j.jeconom.2010.03.034](https://doi.org/10.1016/j.jeconom.2010.03.034).
- [15] Sheppard, K. arch: Autoregressive Conditional Heteroskedasticity (ARCH) and Other Tools for Financial Econometrics: Python package, version 7 [Электронный ресурс] / K. Sheppard. — 2017. — URL: <https://github.com/bashtage/arch> (дата обращения: 28.05.2026).
- [16] Tetlock, P. C. Giving Content to Investor Sentiment: The Role of Media in the Stock Market / P. C. Tetlock // Journal of Finance. — 2007. — Vol. 62, No. 3. — P. 1139–1168. — DOI: [10.1111/j.1540-6261.2007.01232.x](https://doi.org/10.1111/j.1540-6261.2007.01232.x).
- [17] Yang, H. Deep Reinforcement Learning for Automated Stock Trading: An Ensemble Strategy / H. Yang, X.-Y. Liu, S. Zhong, A. Walid // Proceedings of the First ACM International Conference on AI in Finance. — 2020. — DOI: [10.1145/3383455.3422540](https://doi.org/10.1145/3383455.3422540).